

卡方检验推导

符号说明

- O : 观察频数 (observed frequency)
- E : 期望频数 (expected frequency)
- k : 类别数 (number of categories)
- n : 总观测数 (total observations)
- r : 行数 (number of rows)
- c : 列数 (number of columns)
- χ^2 : 卡方统计量 (chi-square statistic)

拟合优度检验 (Goodness-of-Fit Test)

目的

检验一个分类变量的观察分布是否与理论分布一致。

推导

- 零假设下, 期望频数 $E_i = np_i$, 其中 p_i 为理论概率
- 卡方统计量:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

- p_i 较小时, $np_i(1 - p_i) \approx E_i$, 根据中心极限定理, 标准化残差 $Z_i = \frac{O_i - E_i}{\sqrt{E_i}}$ 近似标准正态。
- 在零假设下, χ^2 近似服从自由度为 $k - 1$ 的卡方分布 (自由度减少 due to $\sum O_i = n$)

独立性检验 (Test of Independence)

目的

检验两个分类变量是否独立。

推导

- 列联表中, 观察频数为 O_{ij}
- 在独立性零假设下, 期望频数 $E_{ij} = \frac{R_i C_j}{n}$, 其中 R_i 为行和, C_j 为列和

- 卡方统计量:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

- 在零假设下, χ^2 近似服从自由度为 $(r-1)(c-1)$ 的卡方分布 (自由度减少 due to $\sum_i O_{ij} = C_j, \sum_j O_{ij} = R_i$)

备注

- 推导基于多项分布和正态近似, 要求大样本 (通常 $E_i \geq 5$)
- 卡方分布近似依赖于中心极限定理和二次型理论