

硬间隔支持向量机（SVM）——公式推导

1. 符号说明

- 训练集: $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, 其中 $\mathbf{x}_i \in \mathbb{R}^d$, $y_i \in \{-1, +1\}$
- 决策超平面: $\mathbf{w}^\top \mathbf{x} + b = 0$, 其中 $\mathbf{w} \in \mathbb{R}^d$, $b \in \mathbb{R}$
- 函数间隔: $y_i(\mathbf{w}^\top \mathbf{x}_i + b)$
- 几何间隔: $\frac{y_i(\mathbf{w}^\top \mathbf{x}_i + b)}{\|\mathbf{w}\|}$

目标: 最大化几何间隔。

2. 原始优化问题

最大化几何间隔等价于:

$$\max_{\mathbf{w}, b} \frac{1}{\|\mathbf{w}\|} \quad \text{subject to} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \forall i$$

等价转化为凸二次规划问题:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{subject to} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \forall i \quad (\text{P})$$

3. 拉格朗日对偶

引入拉格朗日乘子 $\alpha_i \geq 0$, 构造拉格朗日函数:

$$\mathcal{L}(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i [y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1]$$

对 $\mathbf{w}$ 和 b 求偏导并令其为零:

- $\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i$
- $\frac{\partial \mathcal{L}}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$

将 (1) 和 (2) 代入 $\mathcal{L}$, 得对偶函数:

$$\mathcal{L}_D(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j$$

对偶优化问题为：

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^{\top} \mathbf{x}_j \text{ subject to } \alpha_i \geq 0 \forall i, \sum_{i=1}^n \alpha_i y_i = 0 \quad (\text{D})$$

4. KKT 条件与支持向量

最优解满足 KKT 互补松弛条件：

$$\alpha_i [y_i (\mathbf{w}^{\top} \mathbf{x}_i + b) - 1] = 0, \quad \forall i$$

- 若 $\alpha_i > 0$, 则 $y_i (\mathbf{w}^{\top} \mathbf{x}_i + b) = 1$: $\mathbf{x}_i$ 为**支持向量**
- 若 $\alpha_i = 0$, 该样本不影响决策边界

5. 决策函数

由 (1) 得分类器为：

$$f(\mathbf{x}) = \mathbf{w}^{\top} \mathbf{x} + b = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i^{\top} \mathbf{x} + b$$

仅支持向量 ($\alpha_i > 0$) 参与求和。

任取一个支持向量 j , 计算偏置项：

$$b = y_j - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i^{\top} \mathbf{x}_j$$